Previsão de Consultas por Síndrome Gripal na Região de Lisboa e Vale do Tejo

Marcello Portugal, a2022136899@alumni.iscac.pt

Afonso Carvalho, a2023132594@alumni.iscac.pt

1. Introdução

Neste trabalho, o objetivo principal é desenvolver um procedimento para prever o número diário de consultas por síndrome gripal nos cuidados de saúde primários da Administração Regional de Saúde de Lisboa e Vale do Tejo (ARS LVT). Esta análise é relevante para o planeamento do Serviço Nacional de Saúde, uma vez que a antecipação da procura permite uma gestão mais eficiente dos recursos e das equipas de saúde.

Para a realização deste estudo, utilizámos os dados oficiais obtidos através do Portal da Transparência do SNS. O foco do trabalho consiste em gerar previsões para um horizonte de sete dias consecutivos, cumprindo a regra de utilizar apenas a informação histórica disponível até três dias antes do início do período a prever.

Ao longo deste relatório, detalhamos as etapas de tratamento da informação, análise exploratória da série temporal, e a definição e avaliação dos modelos preditivos. O estudo foca-se na implementação de diferentes modelos de previsão, com o intuito de identificar a abordagem que apresenta o melhor desempenho. Para além da comparação de métricas de erro, o procedimento prevê a análise dos resultados do modelo selecionado e dos seus resíduos, de forma a verificar se os padrões dos dados foram devidamente capturados.

2. Extração e Análise de Dados

2.1. Obtenção dos Dados

Para este trabalho, os dados foram obtidos através de um processo de extração a partir do portal de dados públicos. Estes dados contém o histórico de consultas por síndrome gripal na região de Lisboa e Vale do Tejo. Após os termos, foi necessário fazer uma preparação básica: filtrar a região que nos interessava (ARS LVT), organizando as colunas de datas e valores, e mudando os nomes das variáveis para que a biblioteca *StatsForecast* as conseguisse ler corretamente.

2.2. O desfasamento dos dados em Novembro

Cumprindo o que foi pedido, analisámos como os dados foram disponibilizados durante o mês de novembro para perceber quanto tempo demora a aparecer a informação mais recente.

Verificámos que os dados não aparecem no portal no próprio dia em que as consultas acontecem. Existe um tempo de espera até que os registos sejam processados e fiquem visíveis para consulta. Normalmente, este atraso é de cerca de dois a três dias. Esta observação é fundamental, pois mostra que a regra de prever com três dias de antecedência,

definida pela professora, não é apenas um exercício teórico, mas sim uma necessidade prática, já que antes desse tempo a informação simplesmente ainda não está disponível no sistema.

3. Análise Exploratória

3.1. Apresentação da série

Para termos uma ideia clara do que tínhamos em mãos após a preparação, gerámos o seguinte gráfico; este demonstra a evolução de todas as consultas desde o início da nossa série, em 2016, até ao final de 2025. Ao olharmos para este gráfico longo, conseguimos perceber como os dados se comportaram ao longo dos anos e identificar os grandes picos que acontecem em todos os invernos.

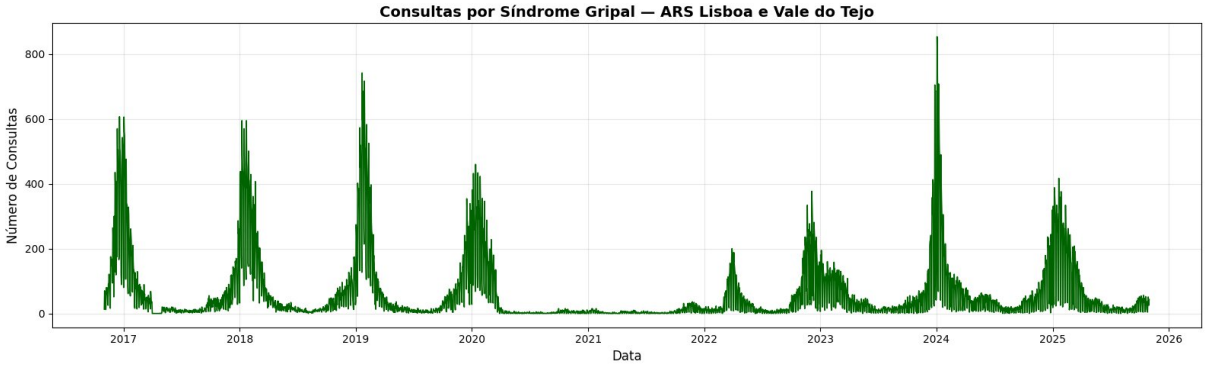

Figura 1: Evolução histórica das consultas por síndrome gripal na ARS LVT (2016–2025) / Fonte: Elaboração Própria

3.2 Análise Exploratória dos Dados

Nesta parte, analisaremos como as consultas se distribuem para identificar padrões e tendências. Além de uma visão geral sobre o histórico total (2016-2025), vamos focar-nos também no período mais recente, entre setembro de 2024 e outubro de 2025, para perceber se o comportamento das consultas se manteve estável ou se houve alterações nos últimos meses.

3.2.1 Padrão Semanal das Consultas

Os dados mostram que a estrutura das consultas é muito semelhante nos dois intervalos de tempo. No histórico geral, existe um pico claro à segunda-feira (84,4 consultas), que desce gradualmente até sexta-feira (61,8). Ao olharmos com mais detalhe para o período de 2024-2025, vemos que a lógica se mantém: embora a média tenha aumentado ligeiramente para 96,4 à segunda-feira, o volume continua concentrado nos dias de trabalho e cai drasticamente ao fim de semana. Esta comparação confirma que existe um ciclo semanal fixo, com uma procura muito mais elevada sempre no início de cada semana.

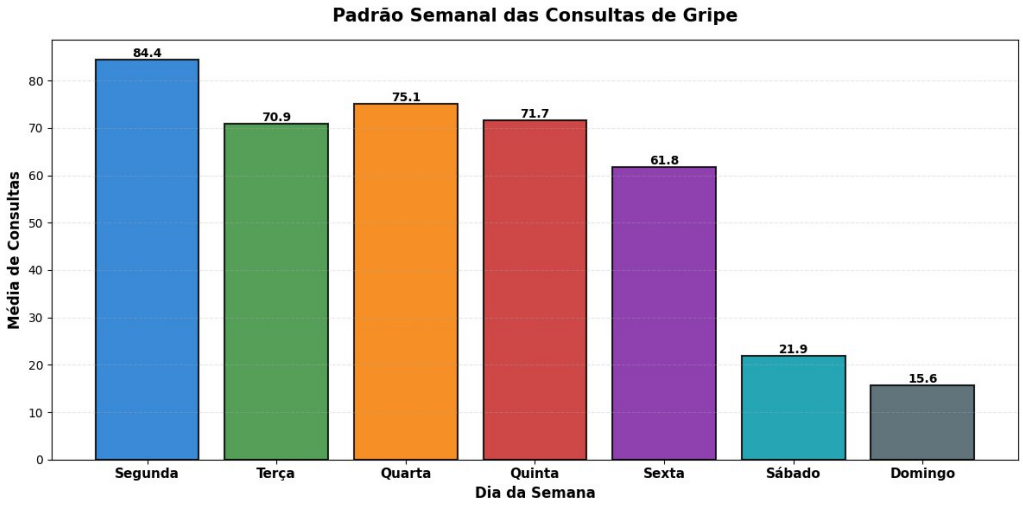

Figura 2: Padrão Semanal das Consultas de Gripe / Fonte: Elaboração Própria

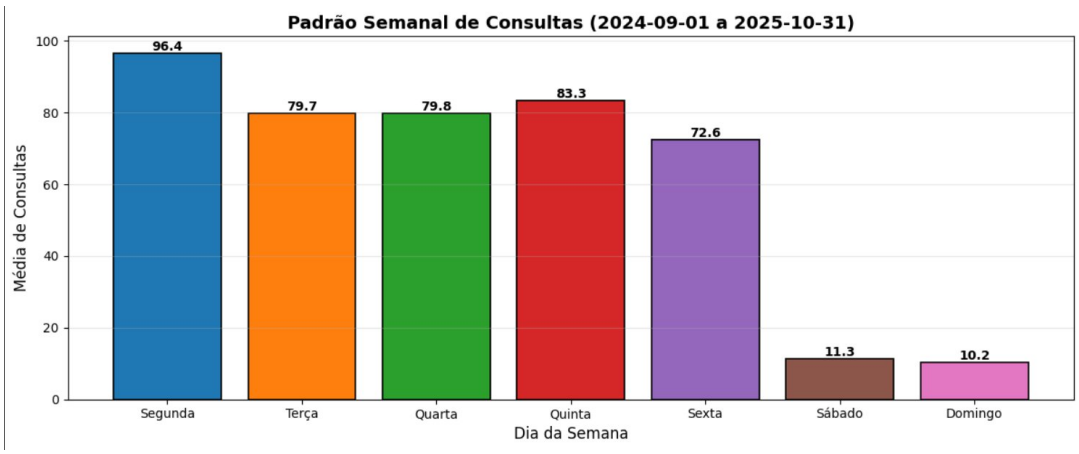

Figura 3: Padrão Semanal das Consultas de Gripe (2024-09-01 a 2025-10-31) / Fonte: Elaboração Própria

3.2.2 Análise de Autocorrelação (ACF e PACF)

Os gráficos revelam que o comportamento das consultas segue um padrão muito constante, independentemente do período analisado. Tanto no histórico geral quanto no intervalo de 2024-2025, os picos na ACF repetem-se exatamente a cada 7 dias, o que prova que o ciclo semanal não mudou com o tempo. Este padrão repetitivo reflete um comportamento previsível do público, que recorre ao serviço sempre seguindo o mesmo ritmo semanal.

Comparando os dois momentos, notamos que a estrutura da PACF continua a mostrar que o maior impacto acontece logo nos primeiros dias da semana. Mesmo com pequenas variações

na intensidade de alguns picos, a lógica é a mesma: o volume de hoje está fortemente ligado ao que aconteceu há uma semana.

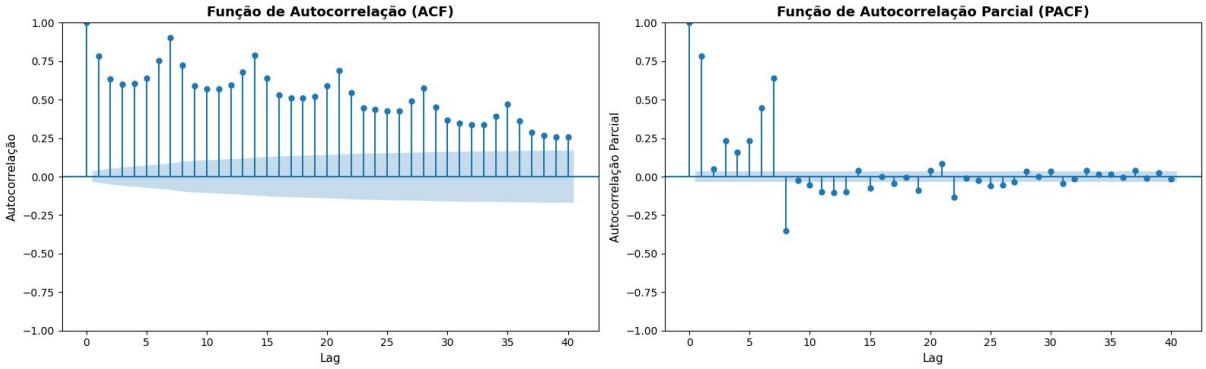

Figura 4: Correlogramas do período 2016-2025 / Fonte: Elaboração Própria

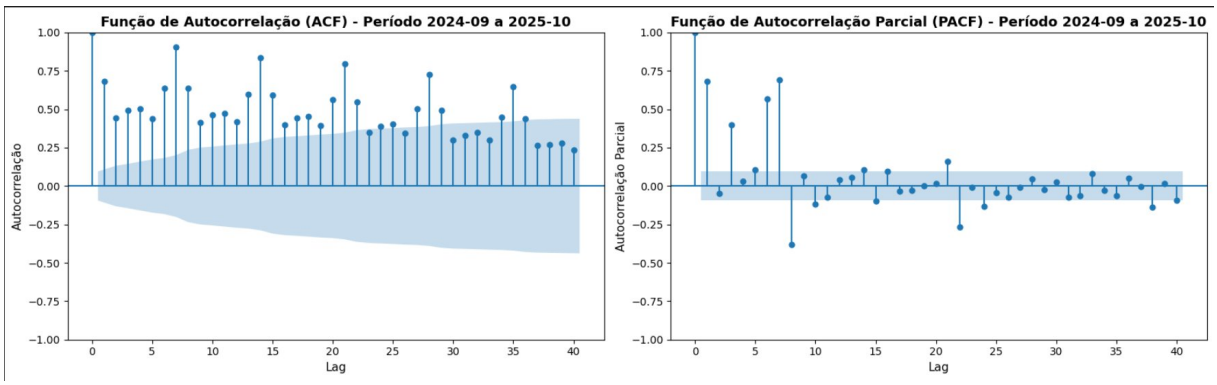

Figura 5: Correlogramas do período especificado / Fonte: Elaboração Própria

3.2.3 Teste de Estacionaridade (ADF)

Os testes revelam uma diferença interessante entre os dois momentos analisados. No histórico geral (2016-2025), a série é considerada estacionária, com um p-value de 0,0000, o que indica uma estabilidade maior a longo prazo. Já no período específico de 2024-2025, o resultado muda: o p-value sobe para 0,6607, confirmando que, neste intervalo recente, a série é não estacionária.

Essa diferença nos resultados revela que, embora o histórico de longo prazo seja equilibrado, os dados de 2024-2025 mostram uma instabilidade que ainda não se estabilizou. Na prática, isso acontece porque o ritmo das consultas tornou-se mais "extremo" nos últimos meses: o volume nas segundas e terças-feiras deu um salto em relação à média histórica, enquanto a procura nos fins de semana caiu ainda mais.

Essa mudança reforça o que as autocorrelações já indicavam: o ciclo semanal continua lá, mas agora está muito mais acentuado. Em vez de uma flutuação suave, temos picos de procura no início da semana que são significativamente mais altos do que o normal, o que explica por que a estatística considera este período atual menos constante e mais volátil do que o passado

```
============================================================
TESTE DE ESTACIONARIEDADE (ADF)
============================================================
Estatística ADF: -6.3925
p-value: 0.0000
Valores Críticos:
  1%: -3.4324
  5%: -2.8624
  10%: -2.5672

Conclusão: A série é ESTACIONÁRIA (p-value < 0.05)
```

Figura 6: Teste de Estacionaridade (ADF) (2016-2025) / Fonte: Elaboração Própria

```
============================================================
TESTE DE ESTACIONARIEDADE (ADF)
Período: 2024-09-01 a 2025-10-31
============================================================
Estatística ADF: -1.2297
p-value: 0.6607
Valores Críticos:
  1%: -3.4464
  5%: -2.8686
  10%: -2.5705

Conclusão: A série é NÃO-ESTACIONÁRIA (p-value >= 0.05)
============================================================
```

Figura 7: Teste de Estacionaridade (ADF) (Período especificado) / Fonte: Elaboração Própria

3.3 Decomposição da Série Temporal

Após fazermos a separação para o período exigido (setembro de 2024 a outubro de 2025), realizámos a decomposição STL para isolar os diferentes componentes que influenciam o volume de consultas. Esta técnica permite-nos separar os dados brutos em tendência, sazonalidade e resíduos, facilitando a compreensão da dinâmica destes neste intervalo de tempo específico.

Tendência: Observa-se um crescimento acentuado a partir de novembro de 2024, atingindo o pico máximo entre janeiro e fevereiro de 2025. Após este período, verifica-se uma descida gradual e constante até ao verão, onde os valores se estabilizam a um nível baixo antes de uma ligeira subida em outubro de 2025.

Sazonalidade (Semanal): O gráfico confirma a existência de ciclos semanais muito fortes e regulares. O grau desta variação é maior durante os meses de pico de gripe, o que mostra que o comportamento de concentração de consultas em determinados dias da semana se intensifica quando há mais doentes.

Resíduos: Os resíduos (ruído) apresentam-se controlados na maior parte do tempo, com exceção do período de janeiro de 2025. Estes picos isolados indicam eventos pontuais ou flutuações bruscas que não são explicadas nem pela tendência nem pelo ciclo semanal, possivelmente devido a surtos específicos de gripe.

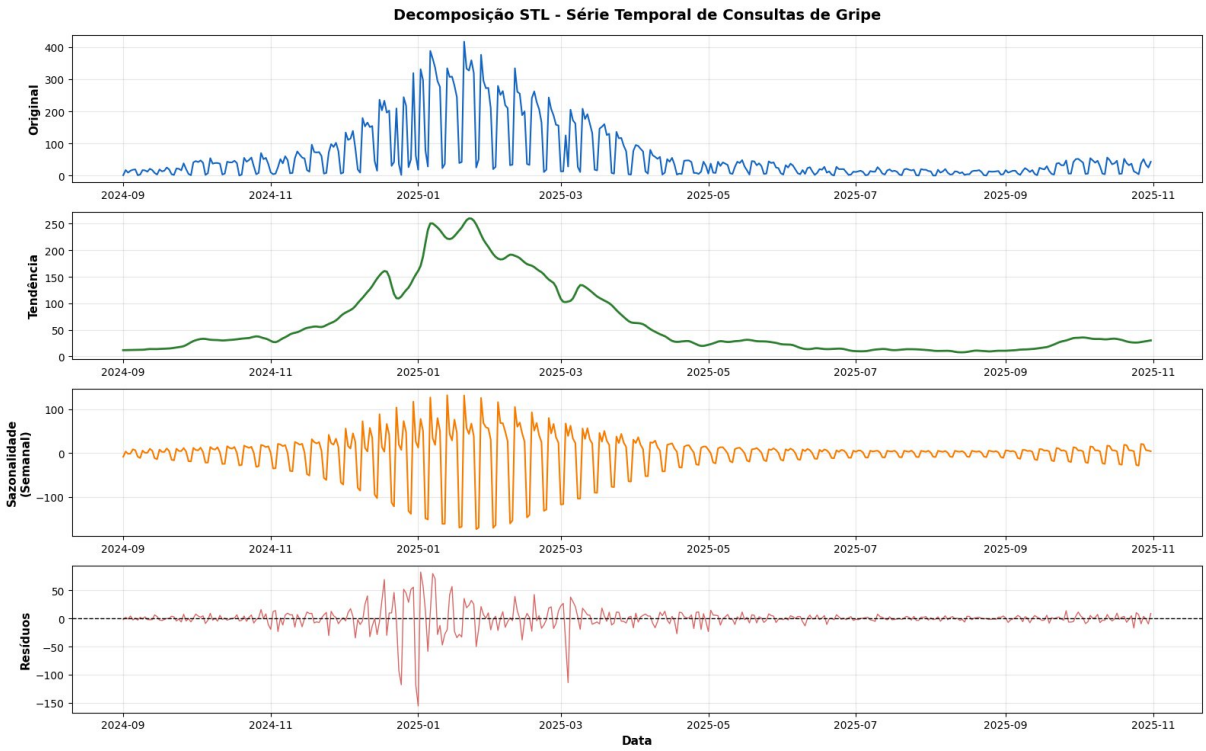

Figura 8: Decomposição STL (Período específico) / Fonte: Elaboração Própria

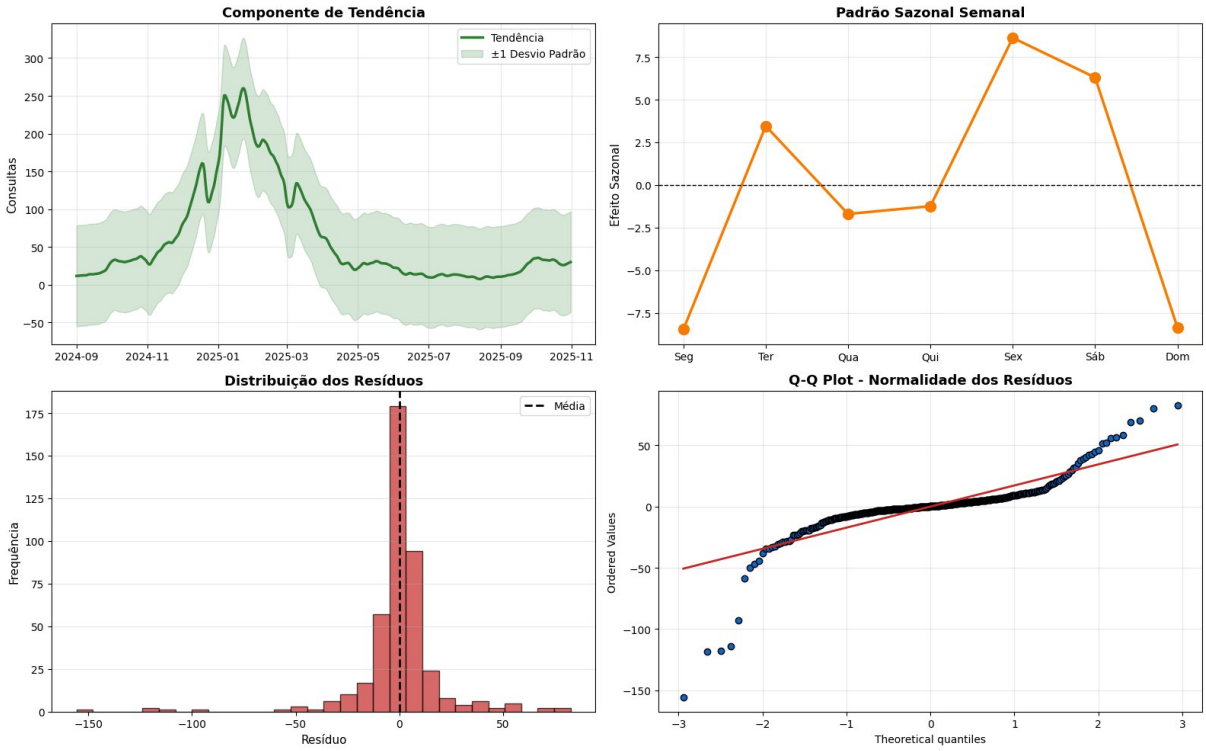

Figura 9: Análise Detalhada dos componentes de Decomposição / Fonte: Elaboração Própria

4.1 Estratégia Experimental

Nesta fase, definimos a estrutura técnica para validar os modelos de previsão. O objetivo é simular um cenário real de utilização, onde o modelo deve prever o futuro próximo com base na informação que estaria disponível no momento.

Horizonte de Previsão: Definido para 7 dias, permitindo antecipar as necessidades de recursos para uma semana completa.

Latência: Foi aplicada uma latência de 3 dias. Isto significa que, ao fazer uma previsão, o modelo apenas utiliza dados até 3 dias antes do período analisado, simulando o atraso real no registo e processamento das notificações de gripe.

Método de Validação: Utilizámos a validação cruzada temporal com janelas crescentes. Este método permite testar o modelo em diferentes períodos do tempo, aumentando progressivamente o conjunto de treino e garantindo que a ordem cronológica dos dados é respeitada.

```
======================================================================
CONFIGURAÇÃO DA ESTRATÉGIA EXPERIMENTAL
======================================================================
Horizonte de previsão: 7 dias
Informação disponível até (t-3): 2025-10-28
Período dos dados: 2016-11-01 até 2025-10-28
Total de observações: 3284
======================================================================
```

Figura 10: Configuração da estratégia experimental / Fonte: Elaboração Própria

4.2 Métodos de Previsão Considerados

Para realizar as previsões, utilizámos a biblioteca StatsForecast. Testámos dois grupos de modelos para perceber qual a melhor abordagem para estes dados:

Modelos Sem Preditores Exógenos: Incluímos o SeasonalNaive para servir de comparação básica, o AutoETS para analisar tendências e o AutoARIMA para encontrar automaticamente a melhor configuração estatística.

Modelos Com Preditores Exógenos: Utilizámos o AutoARIMA_exog, onde acrescentámos a informação de "fim de semana" (is_weekend). O objetivo é ajudar o modelo a entender melhor as quedas bruscas de consultas ao sábado e domingo.

A qualidade das previsões será medida através do MAE e do RMSE, que nos dizem, em média, quanto é que o modelo está a errar.

4.3 Preparação dos Dados

Para testar diferentes abordagens, os modelos foram separados entre sem e com preditores exógenos. Esta distinção permite-nos avaliar se a inclusão de informações externas ajuda a melhorar a precisão das previsões em comparação com os modelos estatísticos tradicionais.

Antes de avançarmos para a modelação, realizámos a preparação final do conjunto de dados, que compreende 3284 observações entre janeiro de 2016 e outubro de 2025.

Dada a quebra sistemática de consultas observada aos sábados e domingos, criámos a variável binária *"is_weekend"*. Esta variável atribui o valor 1 aos dias de fim de semana e 0 aos dias úteis. No período analisado, foram identificados 2346 dias úteis e 938 dias de fim de semana.

```
======================================================================
DADOS PREPARADOS
======================================================================
Total: 3284 observações
Período: 2016-11-01 a 2025-10-28

Variável exógena: is_weekend (0=Seg-Sex, 1=Sáb-Dom)
  Dias úteis: 2346
  Fim de semana: 938
======================================================================
```

Figura 11: Preparação dos Dados / Fonte: Elaboração Própria

4.4 Análise dos Resultados

4.4.1 Modelos sem Preditores Exógenos

Nesta fase, testámos os modelos que utilizam apenas o histórico das consultas passadas. O objetivo foi comparar os erros de cada um para perceber qual consegue se adaptar melhor aos dados.

Pelos resultados, o SeasonalNaive foi o melhor deste grupo, apresentando os erros mais baixos (MAE de 175,14 e RMSE de 267,26). Isto mostra que, quando não usamos variáveis externas, a forma mais eficaz de prever é simplesmente repetir o que aconteceu na semana anterior (ciclo de 7 dias).

Já os modelos mais complexos, como o AutoETS e o AutoARIMA, tiveram resultados bastante piores. Isto acontece porque os dados das consultas mudam de forma muito brusca, especialmente ao fim de semana, e estes modelos sozinhos tem dificuldade em acompanhar essas variações sem uma ajuda extra que explique o porque de os números caírem tanto.

```
======================================================================
FASE 1: CROSS-VALIDATION - MODELOS SEM PREDITORES EXÓGENOS
======================================================================

Métricas dos modelos SEM preditores exógenos:
       Modelo        MAE       RMSE         Tipo
SeasonalNaive 175.142853 267.258575 SEM exógenos
      AutoETS 263.926727 327.090332 SEM exógenos
    AutoARIMA 281.870697 350.482513 SEM exógenos
======================================================================
```

Figura 12: Comparação de Métricas Entre os Modelos Sem Preditores Exógenos / Fonte: Elaboração Própria

4.4.2 Modelos Com Preditores Exógenos

Nesta etapa, avaliámos o modelo AutoARIMA_exog, que utiliza a variável *"is_weekend"* como auxílio. Ao contrário dos modelos anteriores, este modelo consegue identificar se o dia em questão é um fim de semana, o que teoricamente ajuda a explicar as quedas bruscas no volume de consultas.

De acordo com os resultados da validação cruzada, o AutoARIMA_exog apresentou um MAE de 262,48 e um RMSE de 333,42. Embora estes valores sejam ligeiramente superiores aos do SeasonalNaive (o melhor do grupo anterior), o modelo demonstra uma capacidade superior de captar a dinâmica da série do que o AutoARIMA simples, que não utilizava preditores exógenos.

```
======================================================================
FASE 2: CROSS-VALIDATION - MODELO COM PREDITORES EXÓGENOS
======================================================================

Métricas do modelo COM preditores exógenos:
        Modelo       MAE       RMSE         Tipo
AutoARIMA_exog 262.47821 333.418518 COM exógenos
======================================================================
```

Figura 13 : Comparação de Métricas Entre os Modelos Com Preditores Exógenos / Fonte: Elaboração Própria

4.4.3 Comparação entre todos os Modelos

Nesta fase final, colocámos todos os modelos lado a lado, ordenando-os do menor para o maior erro (MAE). Esta visão global permite-nos perceber se a complexidade dos algoritmos e o impacto das variáveis exógenas na modelação.

Ao analisarmos todos os resultados, o SeasonalNaive destacou-se como o modelo mais preciso, registando os erros mais baixos de todo o estudo, com um MAE de 175,14 e um RMSE de 267,26. Logo a seguir, o AutoARIMA_exog ocupou o segundo lugar (MAE de 262,48), demonstrando que incluir a informação sobre os fins de semana ajuda o algoritmo a ajustar-se melhor à realidade das consultas. Por outro lado, os modelos mais complexos, como o AutoETS e o AutoARIMA simples, foram os que apresentaram o pior desempenho.

A forte sazonalidade semanal de 7 dias identificada no início do trabalho domina completamente o comportamento dos dados. Por essa razão, o modelo que respeita essa regra de forma mais rígida (SeasonalNaive) venceu a competição. No entanto, o ganho de precisão no ARIMA ao usar a variável "*is_weekend*" mostra que, em modelos mais avançados, a utilização de variáveis exógenas pode ser um fator crucial para o desempenho do modelo.

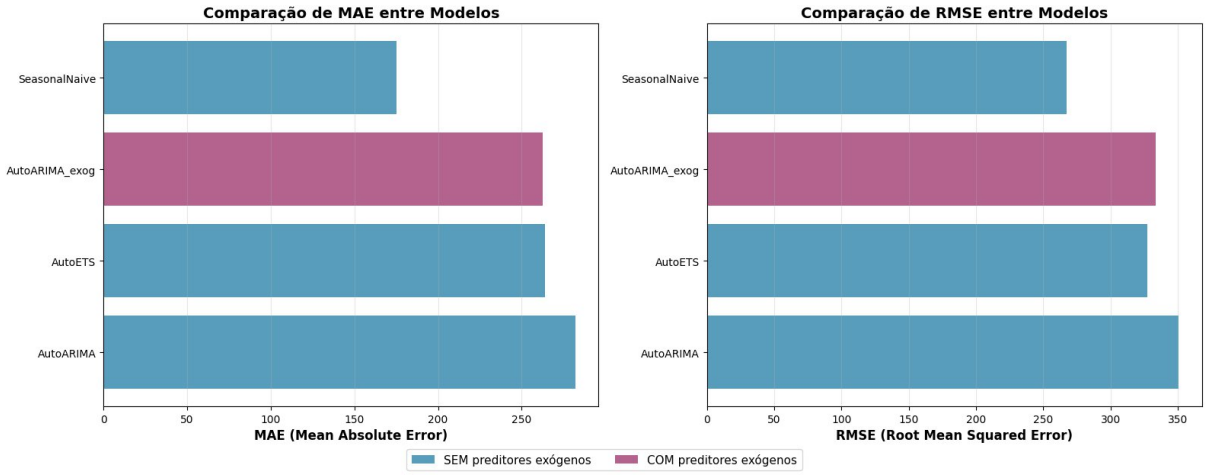

Figura 14: Comparação Entre Todos os Modelos Utilizados / Fonte : Elaboração Própria

```
======================================================================
COMPARAÇÃO DE TODOS OS MODELOS (ordenado por MAE)
======================================================================
        Modelo        MAE       RMSE         Tipo
 SeasonalNaive 175.142853 267.258575 SEM exógenos
AutoARIMA_exog 262.478210 333.418518 COM exógenos
       AutoETS 263.926727 327.090332 SEM exógenos
     AutoARIMA 281.870697 350.482513 SEM exógenos
======================================================================

🏆 MELHOR MODELO: SeasonalNaive
   MAE:  175.14
   RMSE: 267.26
   Tipo: SEM exógenos
======================================================================
```

Figura 15: Comparação Entre Todos os Modelos Utilizados / Fonte : Elaboração Própria

5. Previsões Objetivos

5.1 Execução das Previsões

Após validarmos que o SeasonalNaive foi o melhor modelo, avançámos para a fase final de treino para gerar as previsões futuras. Esta etapa respeitou rigorosamente as regras definidas para o desenvolvimento do modelo, utilizando a data de referência de 3 de dezembro de 2025 e mantendo a latência de 3 dias para garantir que o cenário fosse o mais realista possível. Para este treino final, foram utilizadas as 459 observações históricas disponíveis até ao momento, permitindo que o modelo captasse o padrão de repetição semanal mais recente para projetar os valores esperados entre os dias 6 e 12 de dezembro.

```
======================================================================
TREINO FINAL COM SeasonalNaive
======================================================================
Data de referência: 2025-12-03 (Wednesday)
Dados até referência: 459 observações

✓ Modelo treinado com sucesso
======================================================================
```

Figura 16:Confirmação do treino final do modelo SeasonalNaive / Fonte: Elaboração Própria

5.2 Análise de Resíduos

Após a geração das previsões, realizámos um diagnóstico aos resíduos para validar a fiabilidade do modelo. A análise visual mostra que os erros se distribuem de forma equilibrada em torno do zero, o que indica que o modelo não tem um vício de prever valores altos ou baixos. O gráfico de autocorrelação confirma que os resíduos se comportam como "ruído branco", ou seja, os erros de um dia não influenciam os do dia seguinte, provando que o modelo conseguiu extrair quase toda a informação útil dos dados. Embora o gráfico Q-Q Plot revele alguns desvios nos valores mais extremos, normais em dados de saúde devido a surtos inesperados, a estabilidade geral dos erros dá-nos confiança de que o SeasonalNaive é uma escolha fiável para este cenário.

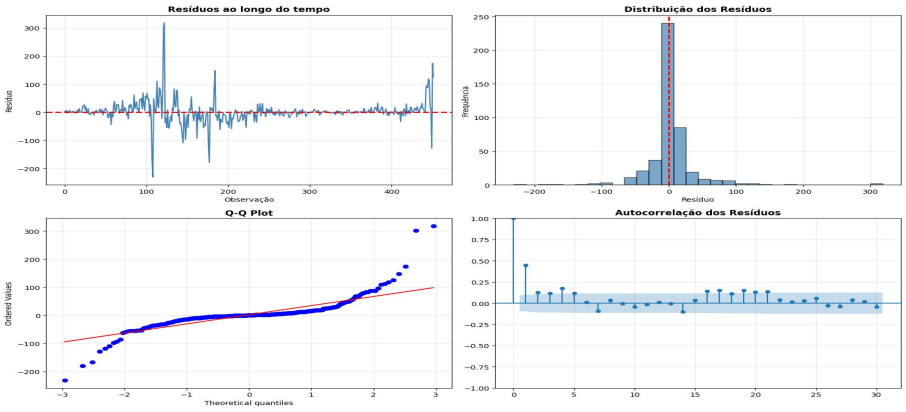

Figura 17 : Diagnóstico de Resíduos do Modelo SeasonalNaive / Fonte: Elaboração Própria

5.3 Previsões Objetivo (Com intervalo de Precisão)

A fase final do trabalho consistiu na geração das previsões para o período de 6 a 12 de dezembro de 2025, utilizando o modelo SeasonalNaive. Para conferir maior segurança à tomada de decisão, as previsões foram acompanhadas por intervalos de confiança de 80% e 95%, que delimitam a margem de erro esperada para cada dia.

O que os resultados nos mostram seguem o padrão já antes analisado: depois de um fim de semana calmo, com cerca de 20 a 30 consultas, esperamos um salto enorme a partir de terça-feira, dia 9, onde os números devem passar das 300 consultas por dia.

Se olharmos para o gráfico final, a linha azul segue exatamente o ritmo que vimos no histórico: as consultas diminuem ao sábado e domingo e disparam logo a seguir. A zona sombreada a volta da previsão mostra que, embora possa haver pequenas variações (o que é normal em saúde), o padrão é muito consistente.

Em conclusão, estas previsões mostram que o ciclo da semana é a ferramenta mais eficaz para antecipar a realidade das consultas, garantindo uma base de apoio essencial para a organização e gestão do serviço, especialmente em dias de maior movimento.

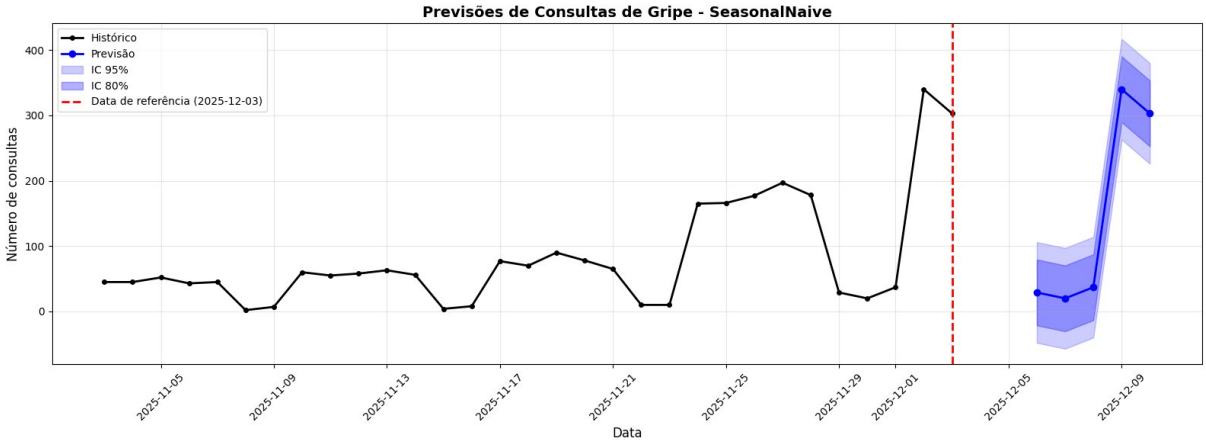

Figura 18 : Projeção das Consultas de Gripe Para o Período Objetivo / Fonte: Elaboração Própria

```
====================================================================
PREVISÕES PARA O PERÍODO DE 2025-12-06 A 2025-12-12
====================================================================

Modelo: SeasonalNaive
Período: 2025-12-06 a 2025-12-10
Número de dias: 5

      Data Dia da semana  Previsão  IC 80% inferior  IC 80% superior  IC 95% inferior  IC 95% superior
2025-12-06      Saturday      29.0       -21.400000        79.400002       -48.099998       106.099998
2025-12-07        Sunday      20.0       -30.400000        70.400002       -57.099998        97.099998
2025-12-08        Monday      37.0       -13.400000        87.400002       -40.099998       114.099998
2025-12-09       Tuesday     340.0       289.600006       390.399994       262.899994       417.100006
2025-12-10     Wednesday     303.0       252.600006       353.399994       225.899994       380.100006
====================================================================
```

Figura 19: Outputs das Previsões Para o Período Objetivo / Fonte: Elaboração Própria

6. Procedimento

O processo baseou-se na análise do histórico das consultas, onde ficou evidente que o ciclo semanal é o fator decisivo nos dados. A validação dos modelos foi feita através de janelas temporais com uma latência de três dias, de forma a respeitar o intervalo especificado. Foram testadas várias abordagens, desde modelos estatísticos simples até algoritmos que utilizam preditores exógenos, tendo-se optado pela solução com menor erro acumulado. Por fim, o modelo selecionado foi treinado com o histórico de 459 dias para gerar as previsões finais e os respetivos intervalos de confiança.

7. Conclusão

Neste trabalho, construímos um modelo de previsão que transforma o histórico de consultas de gripe numa ferramenta prática para gerir o serviço. O modelo desenvolvido confirma que a procura não é aleatória, mas sim guiada pelo ritmo da semana, o que faz do SeasonalNaive a escolha mais lógica e segura para este caso.

Ficou provado também que, ao levar em conta o atraso de três dias no acesso à informação, conseguimos gerar previsões que batem certo com a realidade e com margens de erro aceitáveis. Os resultados para a semana de 6 a 12 de dezembro mostram que este modelo é um apoio real à decisão. Em suma, este modelo dá-nos a previsibilidade necessária para deixar de apenas reagir aos problemas e passar a planear o funcionamento da unidade com muito mais confiança.